



南開大學
Nankai University

《机器学习》

期末课程项目报告

学院：人工智能学院

姓名：刘崇轩

学号：2312801

2025年6月27日

金融风险预测实验报告

一、问题描述

金融风险评估是金融科技领域中的关键问题，尤其是在银行信贷、消费金融和网贷场景中，对于客户是否违约的预测（违约概率）直接关系到资产安全和收益控制。本实验基于某金融机构提供的用户贷款数据，使用 XGBoost 模型预测用户是否存在违约风险（`isDefault`），并输出预测概率和重要特征排序结果。

二、实验配置

1. 语言环境: Python 3.12
2. 开发平台: Windows 11 + Anaconda
3. 核心库版本:
 - `xgboost = 3.0.2`
 - `pandas = 2.2.2`
 - `scikit-learn = 1.5.1`
 - `category_encoders = 2.8.1`
 - `matplotlib = 3.9.2`
4. 输入数据:
 - `train.csv`: 训练集，含字段 `id`, `isDefault` (目标)，若干特征；
 - `testA.csv`: 测试集，含字段 `id`，无标签。
 - 预测目标: `isDefault` (是否违约, 1 表示违约)

三、算法原理

1. XGBoost 简介

XGBoost (eXtreme Gradient Boosting) 是提升树 (Boosting Trees) 的一种高效实现，适用于结构化数据的分类与回归任务。其核心思想是通过加权集成多个弱分类器（通常是 CART 决策树），不断优化目标损失函数。

本实验使用二分类目标函数 (`binary:logistic`) 和 AUC 评价指标 (`eval_metric=auc`)，以区分是否违约的风险。

2. 特征编码与预处理

- (1) 数值特征：用中位数填补缺失；
- (2) 类别特征：用 TargetEncoder 编码（即用目标变量的平滑期望值替代类别）；
- (3) 数值标准化：统一分布以加快模型收敛。

3. 模型训练与验证

- 使用 `StratifiedKFold` 分层交叉验证 (5 折)；

- 每折构建训练集与验证集，分别训练和评估模型；
- 启用 `early_stopping_rounds=50` 避免过拟合；
- 使用 `tree_method='hist'` 以提升训练效率；
- 使用 `scale_pos_weight` 处理类别不均衡。

四、具体实现过程

1. 数据读取与字段划分

- (1) 使用 `pandas` 加载 CSV；
- (2) 提取标签列 `isDefault`，并分离 `id` 列；

2. 特征类型判断与缺失值处理

- (1) 利用 `pandas` 类型判断识别数值和类别特征；
- (2) 数值特征用中位数填补，类别特征填充 `missing` 常量。

3. 编码与标准化

- (1) 类别特征通过 `TargetEncoder` 编码；
- (2) 所有数值列经 `StandardScaler` 标准化处理。

4. 模型训练

- (1) 使用 `StratifiedKFold` 分层交叉验证（5 折）；
- (2) 每一折中构造 `xgb.DMatrix` 数据结构；
- (3) 使用 `xgb.train()` 对每一折进行训练；
- (4) 设置参数并调用 `xgb.train` 训练模型，启用 `early_stopping_rounds=50`；
- (5) 累加每一折的验证 AUC、预测值与特征重要性。

5. 预测与输出

- (1) 所有测试集预测结果做均值融合，保存为 `Result.csv`；
- (2) 计算平均特征重要性，绘制前 20 个重要特征的横向柱状图，保存为 `feature_importance.png`。

五、实验结果与分析

1. 验证集表现（5 折交叉验证 AUC）

折数	验证集 AUC
Fold 1	0.7357
Fold 2	0.7351
Fold 3	0.7340
Fold 4	0.7367
Fold 5	0.7341
平均	0.7351


说明模型具有良好的区分能力，AUC 稳定在 0.735 附近，泛化能力较强，无明显过拟合或欠拟合。

2. 拟合过程观察

- (1) 训练集 AUC 从 0.70 提升至 0.77+，验证集 AUC 在 0.73 附近趋于平稳；
- (2) 使用 early_stopping_rounds=50 时，多在 800~900 轮停止训练，避免拟合；
- (3) 参数设置合理，梯度更新平稳，模型收敛过程可控。

3. 特征重要性分析

- (1) 生成的 feature_importance.png 显示了前 20 个最重要特征（按出现频次）；
- (2) 可作为后续解释模型或优化特征工程的依据。



六、总结

本实验通过合理的数据预处理、特征工程和模型调参，成功构建了一个基于 XGBoost 的信用违约预测模型。模型在 5 折交叉验证中表现稳定，平均 AUC 达 0.7351，具有实际应用的可行性。

同时，通过特征重要性图，我们可以进一步理解模型的决策机制，有助于提升业务可解释性。未来可进一步引入 LightGBM、CatBoost 或深度学习模型以提升表现。

参考文献

- [1] Chen, T. & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. In *KDD 2016*. <https://arxiv.org/abs/1603.02754>
- [2] Friedman, J.H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. *Annals of Statistics*.
- [3] XGBoost 官方文档: <https://xgboost.readthedocs.io/>
- [4] category_encoders 文档: https://contrib.scikit-learn.org/category_encoders/